

מטריצה A מעל \mathbb{R} תקרא מטריצה אי-שלילית אם לכל v נכון $v^T A v \geq 0$, מתקיים $v^T A v \geq 0$.

הכאן כ: מטריצה סימטרית A היא אי-שלילית אם מתקיים $A = X X^T$ וניתן לבנות אותה כ:

ביון 1 - תהא A מטריצה סימטרית מעל \mathbb{R} , כך שכל v נכון $v^T A v \geq 0$, מתקיים $v^T A v \geq 0$.

A סימטרית \Leftrightarrow היא ניתנת להסבן אורתוגונלי, במובן קיימת מטריצה אורתוגונלית Q כך e

$$D = Q^{-1} A Q = Q^T A Q, \quad D = \text{diag}\{\lambda_1, \dots, \lambda_n\}$$

כמו כן, מכך A אי-שלילית, ניתן להסיק כי כל הערך העצמי של A הוא אי-שלילי.

D ! A כן מטריצה בלתי-שלילית, מכך $\lambda_1, \dots, \lambda_n$ הם מספרים ממשיים אי-שליליים.

נבנה מתוך $D = (\sqrt{D})^2$, ויתר על כן, משום שהיא שלילית, $\sqrt{D} = \sqrt{D}^T$.

$$A = Q D Q^T = Q \sqrt{D} \sqrt{D}^T Q^T = (Q \sqrt{D})(Q \sqrt{D})^T$$

מתקיים:

$$\blacksquare \quad A = X X^T \quad \text{כאשר } X = Q \sqrt{D}$$

ביון 2: נניח כי $A = X X^T$ יהי v וקטור.

$$\circledast \quad v^T A v = v^T X X^T v = (v^T X)(v^T X)^T$$

נסמן $y = X^T v$. אז y הוא וקטור במרחב \mathbb{R}^n ומתקיים

$$\|y\| \geq 0 \Rightarrow \sqrt{\langle y, y \rangle} \geq 0 \Rightarrow \langle y, y \rangle \geq 0 \Rightarrow y^T I y \geq 0 \Rightarrow$$

$$\Rightarrow (X^T v)^T (X^T v) \geq 0 \Rightarrow (v^T X)(v^T X)^T \geq 0 \stackrel{\circledast}{\Rightarrow} v^T A v \geq 0 \quad \blacksquare$$

23/10/20

שאלה 2

הראו כי אם A, B מטריצות סימטריות, אז $\theta A + (1-\theta)B$ היא מטריצה סימטרית.

נתון: $0 \leq \theta \leq 1$, A, B מטריצות סימטריות.

המטרה: $\theta A + (1-\theta)B$ היא מטריצה סימטרית.

נתון: $0 \leq \theta \leq 1$, A, B מטריצות סימטריות.

נבדוק: $C = \theta A + (1-\theta)B$, נוכיח כי C מטריצה סימטרית.

$$[C]_{i,j} = \theta [A]_{i,j} + (1-\theta) [B]_{i,j} = \theta [A]_{j,i} + (1-\theta) [B]_{j,i} = [C]_{j,i} \Rightarrow C \text{ מטריצה סימטרית}$$

הי' v וקטור.

$$v^T C v = v^T (\theta A + (1-\theta)B) v = [v^T \theta A + v^T (1-\theta)B] v \quad v \propto X = \alpha v X$$

$$= [\theta v^T A + (1-\theta) v^T B] v = \theta v^T A v + (1-\theta) v^T B v \geq 0$$

$$\theta \geq 0, \quad v^T A v \geq 0 \Rightarrow \theta v^T A v \geq 0$$

$$\theta \leq 1 \Rightarrow (1-\theta) \geq 0, \quad v^T B v \geq 0 \Rightarrow (1-\theta) v^T B v \geq 0$$

ולכן C היא מטריצה סימטרית.

23/10/20

עמוד 1

המשפט אינפניטסימלי של גרסייה הוא היסודי של אנליזה וקטורית.

הצורה הכללית של סף γ היא x ווקטור (ממדי) x ווקטור

$$\left(\frac{dy}{dx}\right)_i = \frac{dy}{dx_i} \quad \forall i=1, \dots, n.$$

$$A = \begin{bmatrix} a_{11} & \dots & a_{1n} \\ \vdots & & \vdots \\ a_{n1} & \dots & a_{nn} \end{bmatrix} \quad x = \begin{bmatrix} x_1 \\ \vdots \\ x_n \end{bmatrix} \quad \frac{d(x^T A x)}{dx} = (A + A^T)x \quad \text{כאשר } A \in M_{n \times n}$$

$$x^T A x = x^T \begin{bmatrix} \sum_{j=1}^n a_{1j} x_j \\ \vdots \\ \sum_{j=1}^n a_{nj} x_j \end{bmatrix} = \sum_{i=1}^n x_i \sum_{j=1}^n a_{ij} x_j =$$

$$= \sum_{i=1}^n \sum_{j=1}^n a_{ij} x_i x_j$$

$$\left(\frac{d(x^T A x)}{dx}\right)_q = \frac{d \sum_{i=1}^n \sum_{j=1}^n a_{ij} x_i x_j}{dx_q} =$$

$$= \frac{d a_{qq} x_q^2}{dx_q} + \sum_{j \in [1, n] \setminus \{q\}} \frac{d a_{qj} x_q x_j}{dx_q} + \sum_{i \in [1, n] \setminus \{q\}} \frac{d a_{iq} x_i x_q}{dx_q} =$$

$$= 2 a_{qq} x_q + \sum_{j \in [1, n] \setminus \{q\}} a_{qj} x_j + \sum_{i \in [1, n] \setminus \{q\}} a_{iq} x_i =$$

$$= \sum_{j=1}^n a_{qj} x_j + \sum_{i=1}^n a_{iq} x_i = \sum_{j=1}^n (a_{qj} + a_{jq}) x_j$$

$$(A + A^T) = \begin{bmatrix} a_{11} & \dots & a_{1n} \\ \vdots & & \vdots \\ a_{n1} & \dots & a_{nn} \end{bmatrix} + \begin{bmatrix} a_{11} & \dots & a_{n1} \\ \vdots & & \vdots \\ a_{nn} & \dots & a_{nn} \end{bmatrix} \quad [A + A^T]_{ij} = a_{ij} + a_{ji}$$

$$((A + A^T)x)_q = \sum_{j=1}^n [A + A^T]_{qj} x_j = \sum_{j=1}^n (a_{qj} + a_{jq}) x_j$$

תהי $p = (p_1, \dots, p_n)$ התפלגות דיסקרטית כאשר $\sum_{i=1}^n p_i = 1$! $\forall i=1, \dots, n \quad p_i \geq 0$
 האינטרופיה, אשר מודדת את "הזכאות" של ההתפלגות מוגדרת כ:

$$H(p) = - \sum_{i=1}^n p_i \log p_i$$

כאשר מוגד $0 \log 0 = 0$. השתמש בתכונה זו של פונקציית ההתפלגות הנמדדת

היא בעלת האינטרופיה הגדולה ביותר.

נגדיר פונ' $g: \mathbb{R}^n \rightarrow \mathbb{R}$ כ:

נצבה תחילה p שכל $p_i \geq 0$ ו- $H(p) = - \sum_{i=1}^n p_i \log p_i$ הוא מקסימום קומץ התנאי $g(p) = 1$.

יהי \hat{p} וקטור ההתפלגות אשר אנו מחפשים. נשתמש בתכונה זו:

$$\mathcal{L}(p, \lambda) = H(p) - \lambda(g(p) - 1)$$

$$\nabla \mathcal{L} = 0$$

ונקבע λ, p דבריו

$$\forall q=1, \dots, n \quad (\nabla \mathcal{L})_q = \frac{d\mathcal{L}}{dp_q} = \frac{dH(p)}{dp_q} - \lambda \frac{dg(p)}{dp_q} =$$

$$= \frac{d(-\sum_{i=1}^n p_i \log p_i)}{dp_q} - \lambda \frac{d(\sum_{i=1}^n p_i)}{dp_q} =$$

$$= \frac{d(-p_q \log p_q)}{dp_q} - \lambda \frac{dp_q}{dp_q} = -\left(\log p_q + p_q \cdot \frac{1}{p_q}\right) - \lambda = -\log(p_q) - 1 - \lambda$$

$$(\nabla \mathcal{L})_{n+1} = \frac{d\mathcal{L}}{d\lambda} = \frac{d(H(p))}{d\lambda} - \lambda \frac{d(g(p))}{d\lambda} = -(\sum_{i=1}^n p_i - 1)$$

$$\begin{cases} -\log(p_i) - 1 - \lambda = 0 & \forall i=1, \dots, n \\ \sum_{i=1}^n p_i = 1 \end{cases}$$

23/10/20

$$\begin{cases} -\log(p_i) - 1 - \lambda = 0 \\ \sum_{i=1}^n p_i = 1 \end{cases}$$

$$\forall i=1, \dots, n \Rightarrow p_1 = p_2 = \dots = p_n = \frac{1}{n}$$

$$\lambda = -\log\left(\frac{1}{n}\right) - 1 = \log(n) - 1, \quad \sum_{i=1}^n \frac{1}{n} = 1 \quad \checkmark$$

מכאן נובע שהאנטיבוי'ה ממוקסמת כאשר ההתפלגות אחידה.

סמוכן, התפלגות מאולף אי השוויון של הוסיקובוויץ, אך היא מתקיימת על התוצאה שיהיה האלן, (פחות $\frac{1}{n} \geq 0$). התוצאה מתאימה צדדית האנטיבוי'ה כמקרה יחיד וצדדית של ניסוי

מתקיימת, כאשר ההתפלגות היא אחידה, אי הוצאת שני קובי'ה התוצאה היא היתוך מלא

מכאן כי ההתפלגות. ■

23/10/20

עמוד 3

יהיו X_0, \dots, X_{n-1} n משתנים מקיימים תכונות קבועות, חלופיים $(\forall i, X_i \in [0, \infty))$

הם פונקציות התפלגות קבועות f_x ונכח סדרם מותנה

$$P[X_0 \geq \max\{X_1, \dots, X_n\}] = \frac{1}{n}$$

נניח בהוכחה הבאה:

$$P[X_0 \geq \max\{X_1, \dots, X_n\}] = \int_0^\infty (F_{X_0}(a))^{n-1} \cdot f_{X_0}(a) da$$

כאשר $F_x(a)$ היא פונקציית ההתפלגות המצטברת של X_0 בנקודה a

! $f_x(a)$ היא פונקציית הצפיפות של X_0 בנקודה a .
הסימנים
העליונים

$$P[X_0 \geq \max\{X_1, \dots, X_n\}] =$$

$$= \int_{a=0}^\infty f_{X_0}(a) \cdot P(X_1 \leq a | X_0 = a) \cdot P(X_2 \leq a | X_0 = a \wedge X_1 \leq a) \dots$$

$$\stackrel{\text{לפי תכונת
המשתנים
הקבועות}}{=} \int_{a=0}^\infty (P(X_0 \leq a))^{n-1} \cdot f_{X_0}(a) da \stackrel{\text{לפי הגדרה}}{=} \int_0^\infty (F_{X_0}(a))^{n-1} \cdot f_{X_0}(a) da$$

באינטגרל לעיל פונקציית ההתפלגות המצטברת היא המשתנה הקבוע של פונקציית הצפיפות.

$$F_x(a) = \int_{-\infty}^a f_x(a) da, \quad f_x(a) = F'_x(a)$$

$$P[X_0 \geq \max\{X_1, \dots, X_n\}] = \int_{a=0}^\infty (F_{X_0}(a))^{n-1} \cdot f_{X_0}(a) da =$$

$$= \int_{a=0}^\infty (F_{X_0}(a))^{n-1} \cdot F'_{X_0}(a) da = F_{X_0}(a) \Big|_0^\infty \left(\int_a^b f(x) dx = \int_a^b f(\varphi(t)) \cdot \varphi'(t) dt \right)$$

$$= \int_{a=0}^\infty u^{n-1} du = \frac{u^n}{n} \Big|_0^\infty = \frac{1}{n} \cdot (F_{X_0}(a) \Big|_0^\infty) = \frac{1}{n} (1 - 0) = \frac{1}{n}$$

23/10/20

שאלה 1

$\{1, \dots, L\}$

Y מקבלת את הרכיבים

X, Y משתנים מקריים באותו

יחיד

$$\ell_{0-1}(\hat{Y}, Y) = \begin{cases} 0 & \hat{Y} = Y \\ 1 & \text{o.w.} \end{cases}$$

ℓ_{0-1} הוא הפונקציה המרחיקת ביותר

$$h = \operatorname{argmin}_{f: X \rightarrow \mathcal{Y}} \mathbb{E}[\ell_{0-1}(f(X), Y)]$$

הפונקציה הטובה ביותר

$$h(x) = \operatorname{argmax}_{i \in \{1, \dots, L\}} P(Y=i | X=x)$$

התוצאה

$$L(h) = \sum_{x \in X} \sum_{y \in Y} P(X=x, Y=y) \cdot \ell(x, h(x))$$

המסלול האופטימלי הוא $\operatorname{argmin}_h L(h)$

$$\ell(y, \hat{y}) = \begin{cases} 0 & y = \hat{y} \\ 1 & y \neq \hat{y} \end{cases} \Rightarrow L(h) = \mathbb{E}[\ell_{0-1}(Y, h(X))] = P(Y \neq h(X))$$

הפרד נכונה בין המסלול האופטימלי לבין המסלול הנתון X יחסי לסיכוי שיהיה שגיאה $\hat{Y} \neq Y$

$$\operatorname{argmax}_{y \in Y} P(Y=y | X=x) = \operatorname{argmax}_{y \in Y} \frac{P(X=x | Y=y) \cdot P(Y=y)}{P(X=x)}$$

שם זה:

$P(X=x) \geq 0$ והוא חיובי ולכן פה מתבטל

$$\operatorname{argmax}_{y \in Y} P(Y=y | X=x) \sim \operatorname{argmax}_{y \in Y} P(X=x | Y=y) \cdot P(Y=y)$$

לכן $x_0 \in X$ הוא ערך קבוע

$$\sum_{y=1}^L P(X=x_0, Y=y) \cdot \ell_{0-1}(y, h(x_0)) =$$

$$= P(X=x_0) \cdot \left[\sum_{y=1}^L P(Y=y | X=x_0) \cdot \ell_{0-1}(y, h(x_0)) \right]$$

התוצאה h^* היא זו שמקסימלת את

$$h^*(x_0) = \operatorname{argmax}_{y \in \{1, \dots, L\}} P(Y=y | X=x_0)$$

23/10/20

שאלה 2

יהא $X = (X_1, \dots, X_n)^T$ וקטור של משתנים מקריים.

נאמר כי X מקבלת גאוסית בהסתברות משתנים סדורים $\mu \in \mathbb{R}^n$ וקובץ שונות $n \times n$ Σ .
 חלוקת פרמטר Σ כפי שניתן להצגות Σ הנתונה Σ וקובץ μ .

$$f(x; \mu, \Sigma) = \frac{1}{(2\pi)^{n/2} |\Sigma|^{1/2}} \cdot e^{-\frac{1}{2} (x-\mu)^T \Sigma^{-1} (x-\mu)}$$

כאשר $X \sim N(\mu, \Sigma)$, $i, j = 1, \dots, n$ וכן $\text{cov}(X_i, X_j) = \Sigma_{ij}$! $E[X_i] = \mu_i$

המטרה נכנסת את כל ההתפלגות שבהן התפלגות פרמטר אחת.

לפיכך הנתונים שלנו הם זוגות $\langle X, Y \rangle$ כאשר $X \in \mathbb{R}^n$! $Y \in \{0, 1\}$.

נשים לב כי מסיכומי השונות בעת ההתפלגות $f_0(x) = f(x|Y=0) \sim N(\mu_0, \Sigma)$

בהתאמה, אך ורקובי התפלגות שונים. $f_1(x) = f(x|Y=1) \sim N(\mu_1, \Sigma)$

תסומי $P(Y=1) = p$

בהינתן תוצאה X , אליו חוזרים להצגת הסיווג $Y=0$ או $Y=1$, $P(Y=1|X)$

נמצא תנאי שיהיה יותר. $P(Y=1|X) > P(Y=0|X)$

$$P(Y=1|X) > P(Y=0|X) \Leftrightarrow$$

$$\frac{f_X(x|Y=1) \cdot P(Y=1)}{f_X(x)} > \frac{f_X(x|Y=0) \cdot P(Y=0)}{f_X(x)} \Leftrightarrow$$

$$\frac{f_X(x|Y=1)}{f_X(x|Y=0)} > \frac{P(Y=0)}{P(Y=1)}$$

23/10/20

$$\frac{f_X(X|Y=1)}{f_X(X|Y=0)} > \frac{P(Y=0)}{P(Y=1)} \Leftrightarrow \frac{f(X, \mu_1, \Sigma)}{f(X, \mu_0, \Sigma)} > \frac{1-p}{p} \Leftrightarrow$$

$$\frac{e^{-\frac{1}{2}(X-\mu_1)^T \Sigma^{-1}(X-\mu_1)}}{(2\pi)^{\frac{n}{2}} |\Sigma|^{\frac{1}{2}}} \cdot \frac{(2\pi)^{\frac{n}{2}} |\Sigma|^{\frac{1}{2}}}{e^{-\frac{1}{2}(X-\mu_0)^T \Sigma^{-1}(X-\mu_0)}} > \frac{1-p}{p} \Leftrightarrow$$

$$e^{-\frac{1}{2}(X-\mu_1)^T \Sigma^{-1}(X-\mu_1) + \frac{1}{2}(X-\mu_0)^T \Sigma^{-1}(X-\mu_0)} > \frac{1-p}{p} \Leftrightarrow$$

$$-\frac{1}{2}(X-\mu_1)^T \Sigma^{-1}(X-\mu_1) + \frac{1}{2}(X-\mu_0)^T \Sigma^{-1}(X-\mu_0) > \log_2\left(\frac{1-p}{p}\right) \Leftrightarrow$$

$$(X-\mu_0)^T \Sigma^{-1}(X-\mu_0) - (X-\mu_1)^T \Sigma^{-1}(X-\mu_1) > 2 \log_2\left(\frac{1-p}{p}\right) \Leftrightarrow$$

$$X^T \Sigma^{-1} X - X^T \Sigma^{-1} \mu_0 - \mu_0^T \Sigma^{-1} X + \mu_0^T \Sigma^{-1} \mu_0$$

$$- [X^T \Sigma^{-1} X - X^T \Sigma^{-1} \mu_1 - \mu_1^T \Sigma^{-1} X + \mu_1^T \Sigma^{-1} \mu_1] > 2 \log_2\left(\frac{1-p}{p}\right) \Leftrightarrow$$

$$-X^T \Sigma^{-1} \mu_0 - \mu_0^T \Sigma^{-1} X + X^T \Sigma^{-1} \mu_1 + \mu_1^T \Sigma^{-1} X > 2 \log_2\left(\frac{1-p}{p}\right) - \mu_0^T \Sigma^{-1} \mu_0 + \mu_1^T \Sigma^{-1} \mu_1 \Leftrightarrow$$

$$X^T (\Sigma^{-1} (\mu_1 - \mu_0)) + ((\mu_1^T - \mu_0^T) \Sigma^{-1}) X > 2 \log_2\left(\frac{1-p}{p}\right) - \mu_0^T \Sigma^{-1} \mu_0 + \mu_1^T \Sigma^{-1} \mu_1 \Leftrightarrow$$

$$X^T (\Sigma^{-1} (\mu_1 - \mu_0)) + (X^T (\Sigma^{-1} (\mu_1 - \mu_0)))^T > 2 \log_2\left(\frac{1-p}{p}\right) - \mu_0^T \Sigma^{-1} \mu_0 + \mu_1^T \Sigma^{-1} \mu_1 \Leftrightarrow$$

$\mu_1^T = \mu_1^T$, 1×1 to $n \times n$
 \downarrow
 $\text{Cov } \Sigma_X$
 \downarrow
 $\text{Cov } \Sigma_X^{-1}$


$$2 X^T (\Sigma^{-1} (\mu_1 - \mu_0)) > 2 \log_2\left(\frac{1-p}{p}\right) - \mu_0^T \Sigma^{-1} \mu_0 + \mu_1^T \Sigma^{-1} \mu_1$$

24/10/20

$$P[Y=1|x] = P[Y=0|x]$$

חסם ההכרחי עדיין לא מוגדר ע"י קבוצת נקודות שבהן

מני וזורה הבלתי של המידע הבלתי (באשר $d > 1$) ?




בתצפית ראשון את המידע אנו $d=1$.

בתורה כל וקטור המסר הוא וקטור מממד d (סדר) שהוא

מקובץ המידע שההתפלגות בממד זה.

עבור המידע בו $d=2$ ההתפלגות של

Y בנענו (התפלגות נורמלית) נראית כך:



בנוסף לכל אסד מן המידע ישנה התפלגות נורמלית.

עם גילוי מסומנות ותוספת מסומנות המידע קטן.

תכן בהצגתו דקלס מסם הבלתי אנו בממד d נשונה בין d "כפוף" שבאנו. אנחנו מסם מממד d .

אנו מידע d נכבד חלוצי את כל V אשר מקיימים

$$V = \{v \in \mathbb{R}^n \mid P(Y=1|v) - P(Y=0|v) = 0\}$$

מסד 4.800 :

$$V = \left\{ v \in \mathbb{R}^n \mid \underbrace{2v^T (\Sigma^{-1}(\mu_1 - \mu_0))}_{u \in \mathbb{R}^n} = \underbrace{\log_2\left(\frac{1-p}{p}\right) - \mu_0^T \Sigma^{-1} \mu_0 + \mu_1^T \Sigma^{-1} \mu_1}_{c \in \mathbb{R}} \right\}$$

מסד

$$V = \{v \in \mathbb{R}^n \mid v^T u = c\}$$

V הוא תת מרחב מממד $d-1$, בנוסף מרחב,

אשר מציג ג'ינ' חזאי - מרחב.

24/10/20

שאלה 3

יחיד X_1, X_2, \dots, X_n מתפלגות נורמליות עם תוחלת μ וסטיית תקן σ ידועה. $X_i \in [-3, 5]$

$$S = \sum_{i=1}^n X_i$$

הסתברות של S תלוי ב- n ו- σ ו- μ ו- $N \in \mathbb{N}$ ו- $n > N$

$$P(S > n^2 + 0.2n) < 0.1$$

נניח $P[-3 \leq X_i \leq 5] = 1$ ו- $\mu = 1$ ו- $\sigma = 1$

$$\bar{X} = \sum_{i=1}^n X_i / n = \frac{S}{n} \Rightarrow S = n\bar{X}$$

$$E[\bar{X}] = E\left[\frac{S}{n}\right] = \frac{1}{n} E[S] = \frac{n}{n} = 1$$

$$P(|\bar{X} - E[\bar{X}]| \geq \varepsilon) \leq 2e^{-\frac{n\varepsilon^2}{(b-a)^2}}$$

$$P(S > n^2 + 0.2n) = P(n\bar{X} > n^2 + 0.2n) \stackrel{n>0}{=} P(\bar{X} > n + 0.2) = P(\bar{X} - 1 > n - 0.8)$$

$$P(\bar{X} - 1 > n - 0.8) = P(\bar{X} - E[\bar{X}] > n - 0.8) \leq P(|\bar{X} - E[\bar{X}]| > n - 0.8) \stackrel{\text{רצוי}}{<} 0.1 \Rightarrow$$

$$2e^{-\frac{n(n-0.8)^2}{(5-(-3))^2}} < 0.1$$

$$e^{-\frac{n(n-0.8)^2}{64}} < 0.05$$

$$-N(N-0.8)^2 \leq 64 \log(0.05)$$

$$N^3 - 1.6N^2 + 0.64N \geq -64 \log(0.05) \geq 64 \cdot 1.5 = 96$$

$$125 - 40 + 3.2 = 88.2 < 96$$

$$N=5 \text{ לא מספיק}$$

$$216 - 57.6 + 3.84 > 162 > 96$$

$$N=6 \text{ מספיק}$$

$$N=6 \text{ תשובה}$$

נניח כי אנו מעוניינים בתהליך אצטד ממשותף M שברים.

נניח כי L_j נבדלים $0 \leq L_j \leq 1$ יחידות זמן.

המטרה היא רשימת אור המשותף L השברים כך שיהיו מלאכות באופן מקסימלי.

ב שיתוף אצטד א ממשותף ובאופן גסות שיהיה סבס הבנתם של ממשותף.

$$L = \sum_{j=1}^n L_j$$

נלדי

עם אצטד ממשותף באופן גסות של שיתוף הוא $\frac{L}{M}$. יענה שלבדיותם שלבים ספריים.

כל, אך הנה כוונתם סתם את הבדלותם של מתן המשותף באופן אקראי.

נניח כי אנו ניתנים ממשותף באופן אקראי עם משימה, עם תכונה.

$$R_{i,j} = \begin{cases} L_j & \text{המשימה הנ נתנה רשימתו} \\ 0 & \text{אסרת} \end{cases}$$

נלדי :

$$R_i = \sum_{j=1}^n R_{i,j} \quad (\text{סך הכולם א נטית הו})$$

מהי התוחלת של R_i ?

תוחלת של קבוע

$$\sum_{i=1}^m R_i = L \Rightarrow$$

תנאיית קוולר
קיימת סבסגו מ"מ תלויים

$$\mathbb{E}[\sum_{i=1}^m R_i] = \mathbb{E}[L] = L \Rightarrow$$

$$\sum_{i=1}^m \mathbb{E}[R_i] = L \quad \text{סימטריה בין נטייתם} \Rightarrow$$

$$\mathbb{E}[R_i] = \frac{L}{m}$$

24/10/20

$$\mathbb{E}[R_i] = \frac{L}{m}$$

אנו רוצים לחסום את ההסתברות שהאלמנט i יהיה גדול מ- $(1+\delta)$ מהערך הממוצע $\mathbb{E}[R_i]$ כאשר $\delta = 10\%$.

תוצאת האי-שוויון חצי-מרכז המסה של L ו- m היא $\mathbb{E}[R_i] = \frac{L}{m}$.

$$\mathbb{P}(R_i \geq (1+\delta)\mathbb{E}[R_i])$$

$$R_i = \sum_{j=1}^n R_{ij}$$

$$R_{ij} : i \times j \rightarrow [0, 1]$$

$$\mathbb{E}[R_i] = \frac{L}{m}$$

מתקיימים m תוצאות מתפלגות בלתי תלויות R_{ij} לכל i .

$$\mathbb{P}(R_i > 1.1\mathbb{E}[R_i]) \leq \left(\frac{e^{0.1}}{1.1}\right)^{\frac{L}{m}} < \boxed{0.9925^{\frac{L}{m}}} \quad \text{ישן:}$$

כלומר, סביר מאוד שכל אחד מהאלמנטים i יהיה קטן מ- $(1+\delta)$ מהערך הממוצע.

אם $\delta = 10\%$ ו- n גדול מאוד, אז:


$$\mathbb{P}(R_1 > (1+\delta)\mathbb{E}[R_1] \vee \dots \vee R_m > (1+\delta)\mathbb{E}[R_m])$$

$$\mathbb{P}\left(\bigcup_{i=1}^m R_i > (1+\delta)\mathbb{E}[R_i]\right) \leq \sum_{i=1}^m \mathbb{P}(R_i > (1+\delta)\mathbb{E}[R_i]) =$$

$$m \cdot \left(\frac{e^{0.1}}{1.1}\right)^{\frac{L}{m}} < \boxed{m(0.9925)^{\frac{L}{m}}}$$

קטלום ממשלת ישראל

$\frac{1}{\lambda_0}$ זרע, label ל, עקראי מרחן 10 קו"מ, האטערנאליזאציע, דיפוזיע, וואג



מגן דקלוגה צ'וקן אטאג' ר' יצחק.